

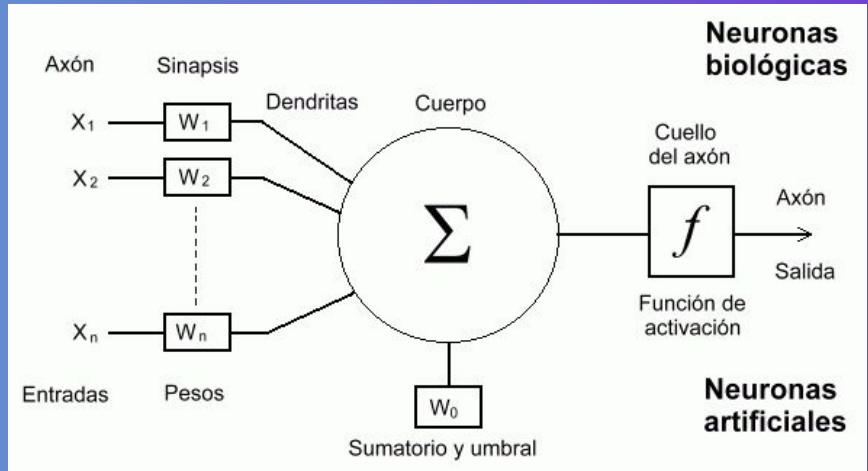

# PERCEPTRÓN Y LÓGICA DIFUSA

---


ALEJANDRO AGUDELO TORO  
CARLOS EDUARDO HINCAPIÉ LÓPEZ  
JUAN MANUEL SÁNCHEZ PAREJA

# INTRODUCCIÓN

A grandes rasgos, las redes neuronales se basan en los modelos que subyacen a las redes neuronales biológicas

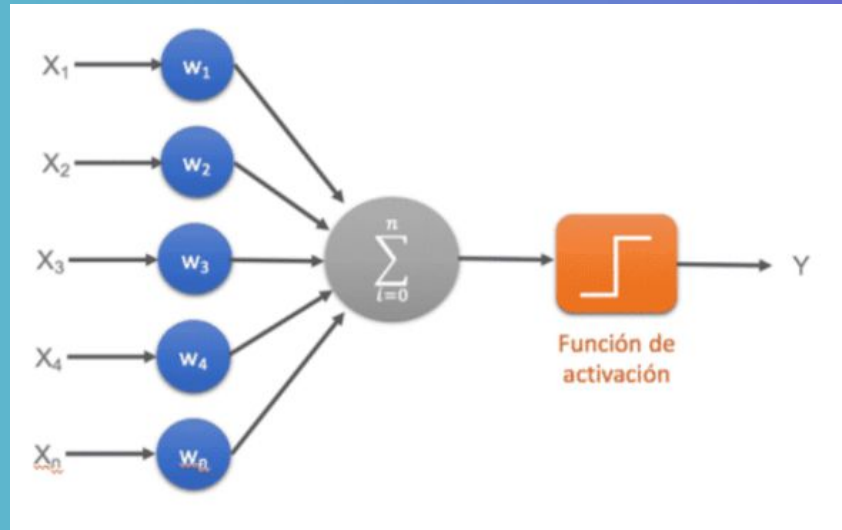


La lógica difusa se basa en la concepción de que la verdad (y la falsedad) no son absolutas. Por este motivo, todos los conceptos que concibe el ser humano tienen cierto grado de certeza




# LA NEURONA ARTIFICIAL

La neurona artificial posee unas entradas en este caso de  $X_1$  a  $X_n$ , y tiene un acceso a la neurona, la neurona artificial es la agrupación del sumador y de la función de activación, entonces las señales pueden ser amplificadas o reunidas este efecto es llamado sinapsis pero en el modelo artificial es llamado los pesos.



# EL PERCEPTRÓN

Para propósitos generales en este caso nosotros tenemos unas entradas ( $x_1, x_2, x_n$ ) Y unos pesos ( $w_1, w_2, w_n$ ) los cuales llegan a un núcleo donde se suman, hay un bias, el bias es el umbral, es un desplazamiento que hay que vencer, hay una función de activación en este caso es una onda cuadrada, cuando alcanzamos el umbral obtenemos una salida de "1" y en caso de que no se alcance obtenemos una salida de "0".



## COMPUERTA AND

**UMBRAL = U = 0.5**

X1	X2	W1	W2	$X1*W1+X2*W2 > U$	Salida
0	0	0.3	0.3	$0*0.3 + 0*0.3 = 0.0$ NO	0
0	1	0.3	0.3	$0*0.3 + 1*0.3 = 0.3$ NO	0
1	0	0.3	0.3	$1*0.3 + 0*0.3 = 0.3$ NO	0
1	1	0.3	0.3	$1*0.3 + 1*0.3 = 0.6$ SI	1

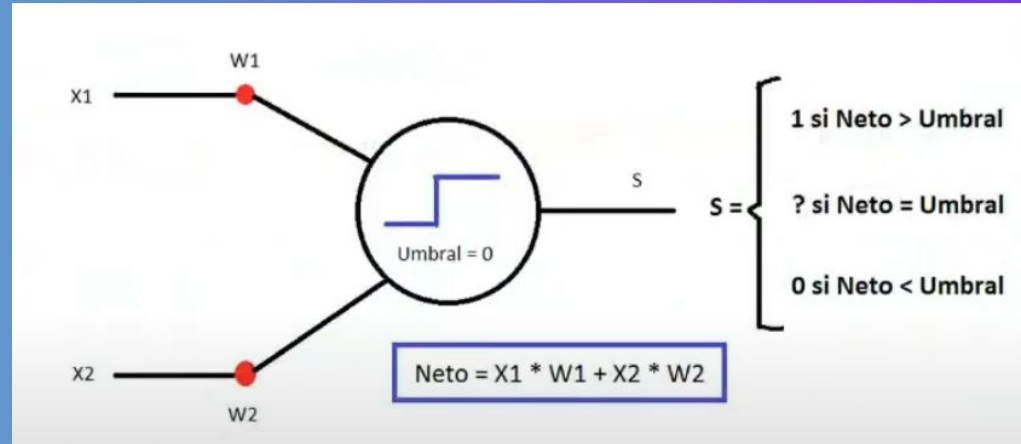
## COMPUERTA OR

**UMBRAL = U = 0.5**

X1	X2	W1	W2	$X1*W1+X2*W2 > U$	Salida
0	0	0.6	0.6	$0*0.6 + 0*0.6 = 0.0$ NO	0
0	1	0.6	0.6	$0*0.6 + 1*0.6 = 0.6$ SI	1
1	0	0.6	0.6	$1*0.6 + 0*0.6 = 0.6$ SI	1
1	1	0.6	0.6	$1*0.6 + 1*0.6 = 0.6$ SI	1


# ECUACIÓN DE UMBRAL

El neto es la sumatoria de toda la energía, En el gráfico se pueden observar los valores para que neto pueda traspasar el umbral, si el neto llega a ser igual al valor del igual podría ser “0” o “1” Esta zona es mejor evitarla.



# ANÁLISIS

## LA RECTA FRONTERA




## ANÁLISIS VECTORIAL

A diagram illustrating the vector analysis of the decision boundary equation. It shows the equation  $x_1 \cdot w_1 + x_2 \cdot w_2 = 0$  in a red box. Below it, the equation is written as  $\begin{bmatrix} w_1 \\ w_2 \end{bmatrix}^T \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$ . To the right, the dot product is expressed as  $|\vec{W}| \cdot |\vec{X}| \cdot \cos(\alpha)$  in a red box. A red arrow points from the dot product equation to the simplified form  $\vec{W}^T \cdot \vec{X} = 0$ .




# CONDICIÓN DE FRONTERA

$$|\vec{W}| \cdot |\vec{X}| \cdot \cos(\alpha) = 0$$





Si el vector  $W$  es perpendicular a todos los puntos de una cierta recta, entonces dicha recta cumple con la restricción de dividir el espacio en dos zonas, en una de las cuales la salida es uno, y en la otra es cero, según se vio en el perceptrón

# SEPARACION ESPACIAL




En el gráfico se puede observar la recta que divide las dos zonas surgiendo de cada una de ellas una salida, la primera de ellas que es hacia donde apunta el vector de pesos  $W$  es igual a 1, y su contraparte que va en dirección contraria al vector de pesos  $W$  es igual a 0

# SOLUCIONES

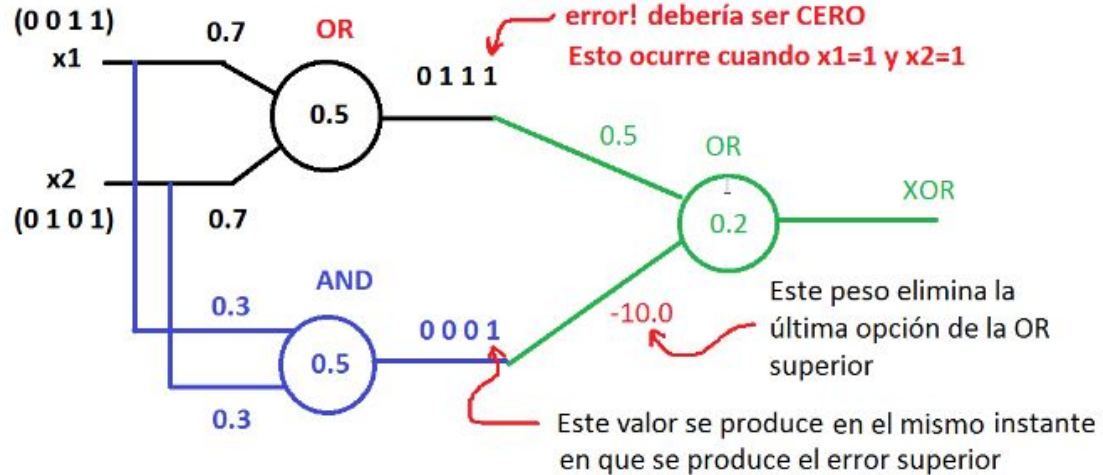




# COMPUERTA XOR



La función XOR no es clasificable con una neurona simple ya que así sea con muchos intentos de acomodar una recta ideal no es posible que en las zonas que quedan estén ubicados rojos y blancos por separado. Para poder clasificar cada área se debe dividir con más neuronas y formar subgrupos

# COMPUERTA XOR - SOLUCIÓN






Cómo entrenar la red neuronal:

1. Se traza un vector  $w$ , que ayuda a separar el área en dos.
2. Convertir el punto en vector. (punto sacado de la base de datos)
3. Calcular el ángulo entre los dos vectores.

Por el valor del ángulo (menor a  $90^\circ$ ) sabemos que la salida es 1.



# LÓGICA DIFUSA


---



La lógica difusa fue investigada en los años sesenta en la Universidad de Berkeley en California, Estados Unidos por Lotfi Zadeh, aunque se podría remontar hasta 2.500 años atrás cuando filósofos griegos, como Aristóteles, consideraban que existían ciertos grados de veracidad y falsedad; o Platón trabajando con grados de pertenencia

# LÓGICA DIFUSA

La lógica difusa permite representar el conocimiento común trabajando con datos numéricos y términos lingüísticos simultáneamente; los términos lingüísticos son sustancialmente menos precisos que los datos numéricos, pero en muchas ocasiones aportan una información más ventajosa para el razonamiento humano.





# LÓGICA DIFUSA

---

$$\mu_A(x) = \begin{cases} 1 & \text{si } x \in A \\ 0 & \text{si } x \notin A \end{cases}$$

$$A = \{(x, \mu_A(x)) \mid x \in U\}$$

La función característica proporciona una medida del grado de similaridad de un elemento de  $U$  con el conjunto difuso

# CONCLUSIONES

---

- Los Conjuntos Difusos, pueden crear modelos que resultan útiles para tratar con la incertidumbre de manera más "natural" que la lógica y la teoría de conjuntos clásicas.
- Se caracterizan por Funciones de Pertenencia que dan flexibilidad a la modelación utilizando expresiones lingüísticas como: mucho, poco, caliente, frío, joven, viejo, alto, bajo.